语义决策模型在统计分析中的应用：方法论框架与研究议程

游尹哲郡（Youyin Zhejun）

中央财经大学

ORCID：0009-0009-5316-8193

2026 年 11 月 10 日

AI 使用声明 本文使用 OpenAI Codex 辅助文献梳理、正文起草与修订、脚本编写及结果复算。作者确定研究问题、论证范围和证据取舍，对稿件内容负责。

作者简介 游尹哲郡，中央财经大学数据科学与大数据技术专业本科生，关注大语言模型、机器学习与自然语言处理。个人履历见作者主页。

前言

最初，我请 Codex 调查新型决策模型对分类与聚类的影响。初稿偏重抽样与总体估计，我要求各节交代既有方法所需的信息、模型如何提供、统计方法如何使用，以及收益如何检验。修订稿聚焦分类与聚类，总体估计列入附录。

我随后提供了论文标题提取错误识别项目的记录，并问“这是一次真实案例，可以纳入文章架构中吗？”Codex 依据参考标签与逐条预测复算指标。在同一推理设置下，启用任务适配器后漏检减少、误报增加，正文据此分析两类错误的代价。聚类采用构造实验，考察关系判断对划分的影响。复现材料见附录C。

在项目中，我使用了 collaborative-research 梳理研究路线和核查证据，并使用 academic-less-ai-tone 审校中文稿件。

摘要

语义决策模型依据自然语言标准提供类别、关系和等级判断。本文结合定向文献研究、真实分类案例与构造聚类实验，讨论这些输出如何用于构造监督信息、分组结构和测量变量。论文标题提取错误识别案例比较同一 NF4 部署下的零样本与任务微调结果。在 1,000 条测试记录上，宏平均 F1 从 71.13% 升至 89.69%，漏检由 242 条降至 34 条，误报由 7 条增至 68 条。非空记录的 Brier 分数从 0.1685 降至 0.0993。九条构造记录的聚类实验显示，查询覆盖影响参考划分的恢复。在异质可靠度条件下，改变并列解的选择规则会反转完整查询图上二元方案与概率加权方案的排序。

关键词 语义决策模型，监督信息获取，约束聚类，概率加权，序数测量，记录链接

1 引言

同一批客户投诉可以按产品类别编码，也可以按故障机制分组。分析访谈时，研究者可依据评分规程记录某项态度的程度。此类标签、关系和等级通常来自人工编码、已有训练标签或表示空间中的距离。研究标准调整后，往往需要重新编码和核验。

本文将依据明确语义标准提供判断的模型统称为语义决策模型，将可调用的判断操作称为决策接口。零样本分类依据标签描述定义任务，语言模型辅助标注将编码规程纳入查询，Jev 等专门接口规定答案类型和返回字段 (Yin et al., 2019; Tan et al., 2024; TypeSafe AI, 2026b)。本文考察研究者能按自然语言标准批量获取类别、成对关系和等级分布时，监督信息、分组结构与测量变量如何构造，以及收益如何在规定的任务和预算下评价。

Tan et al. (2024) 围绕生成、评估与使用综述语言模型标注，ClusterLLM 等研究则利用语言模型判断指导文本聚类 (Zhang et al., 2023; Viswanathan et al., 2024; Wang et al., 2025)。本文以分类、聚类、序数测量和记录链接为例，说明同类判断如何服务于不同统计目标，并区分信息获取与后续使用各自的作用。分类案例使用 Tev1，分析任务监督、部署与错误代价。构造聚类实验固定关系判断来源，比较二元与概率读取，并考察并列解选择规则。

本文开展定向文献研究。接口操作和字段以官方文档及固定版本模型卡为据，任务表现以会议论文、期刊和预印本中的实证结果为据。既有方法和 Jev 材料核查截至 2026 年 10 月 5 日，Tev1 与分类案例补充核查至 10 月 6 日。标题案例复用 10 月 3 日至 6 日的课程实验，新增指标复算、配对重抽样与错误代价分析。既有 SMS 抽样结果见附录B。

2 模型形态、接口属性与方法前史

2.1 结构化判断提供的操作

Jev 文档规定三种操作。Choice 接收选项及说明，返回所选类别、各类概率和置信度。Score 接收有序等级及描述，返回等级概率、索引加权得分和置信度。Noul 返回二元问题回答“是”的赋值概率 (TypeSafe AI, 2026a,d,c)。同一请求可对同一输入提出多项问题 (TypeSafe AI, 2026b)。多项判断可以复用输入，也可能因共享文本与模型而产生相关误差。Choice 的置信度反映分布的集中程度。输出用于统计分析前，应依据参考标签评价概率校准，并结合评分规程检验等级效度及跨任务可比性。

Tev1 基于 Qwen3.5-4B 监督微调，输入包括状态、问题和带字母的选项，输出为选项字母 (Together AI, 2026)。本文分类案例的 NF4 方案在答案位置读取 A、B 的 logit，归一化得到二类分数。概率的含义取决于具体的读取程序。

2.2 既有方法中的对应位置

监督分类根据标记样本学习类别，半监督学习进一步利用未标记记录，零样本方法可借助文本蕴含比较记录与类别描述 (Yin et al., 2019)。语义决策输出既可直接编码，也可作为弱监督的带噪标签来源 (Ratner et al., 2017)。

约束聚类接收同组或异组信息 (Wagstaff et al., 2001)。ClusterLLM 以三元组判断

指导表示学习，以成对判断选择聚类粒度。其他研究分别比较特征、约束与结果修正，研究有限预算下的查询选择，或按置信度与惩罚机制处理自动生成的约束 (Zhang et al., 2023; Viswanathan et al., 2024; Wang et al., 2025; Jia et al., 2026)。表1归纳了这些方法与专门决策接口的联系。

表 1: 语义决策操作与既有方法的联系

操作环节	既有基础	专门接口的可评价变化
表达类别标准	标签描述、自然语言推断、编码规程	类别说明的组织方式及标准修订后的编码工作量
获取关系信息	人工约束、成对相似性、三元组偏好	固定标准下的关系误差、查询数与费用
读取概率输出	概率分类、软标签、加权损失	完整分布的质量及读取与校准的成本
复用观测记录	多属性标注、多任务学习	多标准评价的一致性与核验负担

3 语义判断进入统计分析的统一框架

3.1 从研究标准到分析对象

设 x_i 为第 i 条记录，q 为判断标准，$s(x_i)$ 为提供给模型的信息，$\mathcal{A}$ 为答案空间，m 为固定模型及版本。语义判断与后续分析可表示为

$$O_i = M_m\{s(x_i); q, \mathcal{A}\}, \qquad \widehat{\theta} = \mathcal{T}\big(\{O_i\}, \{Y_i^{\mathrm{ref}} : i \in V\}; \eta\big). \tag{1}$$

其中 O_i 为结构化输出，V 为核验记录集合，Y_i^{ref} 为参考结果，$\mathcal{T}$ 为统计方法，η 为其参数及选择规则。成对和三元组判断分别输入 (x_i, x_j) 和 (x_i, x_j, x_k)。

以投诉严重度为例，研究概念界定何谓严重，评分规程规定等级和所需证据，参考结果记录规程的实施。与参考结果的一致性用于评价编码表现，等级与外部事实的关系用于检验测量效度 (Grimmer and Stewart, 2013)。核验材料应与所用类别定义、上下文和等级描述一致。

3.2 标签、关系与等级的统计用途

表2列出四类任务的输出与用途。记录或记录对的参考标签用于衡量局部误差，划分、等级次序或实体映射用于评价整体结构，回归和总体汇总则反映下游影响。即使局部错误率相同，跨组桥接、极端等级漏判及错误合并也会分别影响划分、程度测量与实体构成。

3.3 预算与优势的评价条件

设 C_q 为标准制定成本，B 为语义判断数，c_M 为单次判断平均成本，v 为参考标签数，c_H 为单个标签平均成本，C_T 为训练及后续处理成本。总成本为

$$C = C_q + Bc_M + vc_H + C_T. \tag{2}$$

表 2: 语义信息进入统计方法的主要路径

统计任务	获取的信息	进入方法的方式	主要评价对象
分类与标注	类别判断、类别概率、多属性编码	直接编码、弱监督融合、学生模型训练、人工复核	记录误差、稀有类别、核验量、标准修订成本
聚类	同组关系、成对比较、三元组偏好	约束聚类、关系图、距离或表示学习	目标划分、图覆盖、冲突、概率权重、查询预算
序数测量	按规程获得的等级分布	序数变量、阈值指标、多维测量	评分一致性、等级使用、跨组可比性、编码敏感性
记录链接	同一实体判断、比较证据	候选匹配、概率链接、整体匹配	候选覆盖、错误合并、实体计数、链接后分析

一次请求可包含多项判断，应另报请求数、输入输出规模及实际费用。分阶段记录训练、验证和核验标签，单位成本不同时分别加总。已有标签的取得成本与新增投入应分列。标准反复调整时，累计规程修订和重新核验的费用。

在目标任务标签较少、标准明确且输出可复用的场景，可在同一标准下比较等成本时的误差，或达到同一误差上限所需的费用。最终评价样本应独立于标准调整。

4 分类中的监督信息

4.1 直接编码与目标任务标签

分类事先规定类别清单与归类标准。语义判断让类别说明直接参与预测。零样本指目标任务未使用训练标签，预训练仍提供语言和领域信息 (Yin et al., 2019)。模型返回 K 个互斥类别的概率 $\widehat{p}_{ik}$ 时，可取最大概率类别，也可按误分类代价选择行动

$$\widehat{a}_i = \arg\min_{a \in \mathcal{D}} \sum_{k=1}^{K} L(a,k)\widehat{p}_{ik}. \tag{3}$$

行动空间 $\mathcal{D}$ 可包括人工复核，损失 L 可纳入漏检、误报和复核成本。采用该规则前应核验概率质量与代价设定。“证据不足”等选项应规定所需证据。同一记录也可按各自的规程编码产品、故障和诉求。单项互斥分类给出候选类别之间的概率分配，多属性的联合结果描述属性共现。

4.2 任务适配、弱监督与学生模型训练

语义规程可与目标任务标签共同用于训练。QLoRA 冻结量化主干，仅训练低秩适配参数 (Dettmers et al., 2023)。第4.4节固定部署条件，比较微调与零样本表现。

语义判断还可与规则、词典和已有分类器共同提供弱标签。弱监督方法估计各来源的质量及相关性，再形成训练标签 (Ratner et al., 2017)。同一模型的多条提示可能产生共有错误，可用参考样本检查其提供的增量信息。完整类别分布也可用于训练学生模型

$f_{\theta k}(x_i)$

$$\widehat{\theta} = \arg\min_{\theta} -\sum_{i=1}^{n}\sum_{k=1}^{K} \widehat{p}_{ik} \log f_{\theta k}(x_i). \tag{4}$$

软标签保留教师模型在类别间的概率分配。比较硬标签训练、软标签训练与相同人工标签预算下的方案时，应使用独立参考标签并计入教师查询和学生训练成本。学生模型与教师的一致性反映知识传递，与参考标签的误差反映目标任务表现。

4.3 人工复核与分类评价

人工复核可优先处理低置信记录、稀有类别和高代价错误。为改正疑难记录而安排的复核侧重困难样本，用于估计总体误差或比例的核验还应覆盖总体中的相关记录类型，并记录选择概率。

分类比较可结合宏平均 F1、类别召回率和混淆矩阵。Brier 分数衡量概率与二元参考结果的平方误差，校准分析对照预测概率与参考频率 (Guo et al., 2017)。计算社会科学的实测研究发现，所比较的决策模型查询费用较低，分类质量随任务变化，并评价了置信度路由 (Ibrahim and Zaki, 2026)。复核效果可据任务、群体和错误代价分别报告，标准变动时还应记录重查和核验的投入。

4.4 案例：论文标题提取错误识别

4.4.1 数据、语义标准与比较设计

本案例复用信息检索课程项目的归档数据和预测 (LeoAndJellyfish, 2026)。参考标签记录实际提取是否正确。训练集和验证集分别含 169,908 条和 42,477 条记录，测试集含 568 条正确提取和 432 条错误提取。按归一化标题核查，三个分区互无重叠。处理规则和模型配置见附录C。

模型仅接收提取文本。规程将完整、连贯的学术标题归为 valid（A），将残缺片段、作者或机构名单、出版元数据、页眉、乱码及混入正文的文本归为 invalid（B）。人工原题名、文献 ID 和参考标签供核对。测试集的 24 条空标题均为错误提取，各方法统一按规则判为 invalid，其余 976 条由模型判断。

监督基线采用词频朴素贝叶斯、平均 Word2Vec 加 SVM、冻结 BERT 表示加 SVM，与 Tev1 微调共用训练和验证分区，按验证集宏平均 F1 选择参数或检查点。NF4 配对比较在同一实例中启用或关闭任务适配器，基础权重、量化、模板、选项顺序和逐条评分程序均固定。Ollama 零样本方案使用 GGUF 权重与 Q4_K_M 量化，读取接口给出的选项分布。NF4 方案用 Transformers 在首个答案位置计算

$$\widehat{p}_i = \frac{\exp(\ell_{iB})}{\exp(\ell_{iA}) + \exp(\ell_{iB})}, \qquad \widehat{Y}_i = \mathbf{1}\{\widehat{p}_i > 0.5\}. \tag{5}$$

其中 $Y_i = 1$ 表示错误提取。两个零样本部署共用测试记录、任务说明及空标题规则，量化、模板构造和评分实现同时变化，比较的是整套部署。

4.4.2 分类结果、概率质量与错误代价

表 3: 同一测试集上的标题提取错误识别（$n = 1{,}000$）

方法	训练标签	准确率	宏 F1	错误类召回	误报	漏检
词频+ NB	169,908	74.70	74.19	70.14	124	129
Word2Vec + SVM	169,908	71.10	70.96	74.31	178	111
冻结 BERT + SVM	169,908	81.40	81.35	88.19	135	51
Tev1/Q4_K_M 零样本	0	67.50	58.83	25.00	1	324
Tev1/NF4 零样本	0	75.10	71.13	43.98	7	242
Tev1/NF4 + QLoRA	169,908	89.80	89.69	92.13	68	34

准确率、宏平均 F1 和召回率以百分数表示。误报指正确提取被判为错误，漏检指错误提取被判为正确。训练标签指本任务用于拟合参数的记录数，监督方案另使用 42,477 条验证标签，预训练投入另行记录。各行包含同一 24 条空标题规则结果。表中为既有预测的独立复算。

表3的 NF4 配对比较中，微调方案的宏平均 F1 高 18.57 个百分点，错误类精确率由 96.45% 降至 85.41%。微调纠正 210 条误判，新增 63 条误判，准确率净增 14.70 个百分点。以 963 个归一化非空标题组为单位，按参考类别进行 10,000 次配对分层自助重抽样，保留组内记录并加回 24 条空标题。宏平均 F1 差异的 95% 百分位区间为 15.46 至 21.78 个百分点，反映固定训练结果与测试来源构成下的重抽样波动。相比冻结 BERT + SVM，微调的宏平均 F1 高 8.34 个百分点，区间为 6.08 至 10.61 个百分点，误报少 67 条，漏检少 17 条。

表4显示，微调后 NF4 的三项概率指标均有改善。微调方案给出错误概率至少为 0.9 的 377 条记录中，平均预测概率为 0.9934，参考错误频率为 0.9204。用于复核时，概率校准和决策阈值应结合两类错误的代价。

表 4: Tev1 错误类概率的评价（非空记录，$n = 976$）

方案	Brier 分数	对数损失	分组校准误差
Ollama/Q4_K_M 零样本	0.2181	0.6307	0.2349
Transformers/NF4 零样本	0.1685	0.5111	0.1704
Transformers/NF4 + QLoRA	0.0993	0.3988	0.1301

分组校准误差按错误类概率的 10 个等宽区间计算，各区间的平均概率与参考频率之差取绝对值，再按记录比例加权。它评价此项指定分组。Brier 与对数损失评价逐条概率。所有值由保存的预测复算，数值越低表示对应评分较好。

设漏检和误报的单位代价为 $c_{\mathrm{FN}} > 0$ 和 $c_{\mathrm{FP}} > 0$。NF4 微调相对零样本的测试误判损失变化为

$$\Delta L = -208c_{\mathrm{FN}} + 61c_{\mathrm{FP}}. \tag{6}$$

当 $c_{\mathrm{FN}}/c_{\mathrm{FP}} > 61/208 \approx 0.2933$ 时，微调方案在固定预测下的测试误判损失较低。部署比较还应计入标签、训练及核验成本。

4.4.3 判断标准与参考标签

课程标签评价实际提取结果，模型依据输入文本判断其是否像一个完整标题。例如，“Notation as a Tool of”是残缺片段，NF4 零样本判为 valid，微调判为 invalid。“Editorial Statement”在形式上完整，原题名为“Special Issue: The Future of Biofeedback Instrumentation”，参考标签与微调判断均为 invalid。前一例可凭标题文本识别，后一例需要参照原文才能核实提取是否正确。后续可在同一规程下比较仅提供标题与补充原文信息时的判断，并记录参考编码的分歧与裁决。

5 语义标准指导的聚类

5.1 关系目标与分组结构

给定表示 z_i，K-means 以组内平方距离最小为目标。约束聚类还可接收同组和异组信息 (Wagstaff et al., 2001)。以投诉为例，若研究目标是故障机制，而表示对产品差异更敏感，可直接询问“这两条投诉是否涉及相同的主要故障机制”。关系标准规定分组依据，簇数可由划分结果确定，名称可在划分后拟定。若事先规定全部类别并逐条归类，则按第4节的分类设计评价。

按唯一主要机制分组适合互斥划分，规程应明确如何认定主要机制。若问题是两条记录是否共享任一故障因素，一条记录可能联系多个组，关系图或重叠聚类更适合表达这种结构。

5.2 查询图、对称性与冲突

设 E 为已查询记录对的集合，$R_{ij}^{(q)}$ 为按标准 q 定义的同组关系，$\widehat{p}_{ij}$ 为模型赋值。为满足同组关系的对称性，可分别查询两种输入顺序，取 $\bar{p}_{ij} = (\widehat{p}_{ij} + \widehat{p}_{ji})/2$，并记录顺序差 $|\widehat{p}_{ij} - \widehat{p}_{ji}|$。平均值的方差为

$$\operatorname{Var}(\bar{p}_{ij}) = \frac{\operatorname{Var}(\widehat{p}_{ij}) + \operatorname{Var}(\widehat{p}_{ji}) + 2\operatorname{Cov}(\widehat{p}_{ij}, \widehat{p}_{ji})}{4}. \tag{7}$$

两次查询共享模型和记录，协方差影响平均值的方差，故应核验对称化后的概率质量。

互斥划分还要求同组关系传递。三对判断中出现两条正边和一条负边时，严格约束相互冲突。稀疏图也须检查正边连通分量内的负边，以发现较长路径导致的冲突。若 p_{ij}、p_{jk} 和 p_{ik} 表示同一随机划分在相同条件信息下的边际概率，由事件的传递性及交集概率下界可得

$$p_{ik} \geq p_{ij} + p_{jk} - 1. \tag{8}$$

分别查询的概率可能违反式(8)。层级分类研究也观察到直接与分解判断的协调性差异 (Joy, 2026)。聚类中需要针对所用关系标准检验这种冲突。

5.3 从关系判断到整体划分

令 $\mathcal{P}$ 为记录的互斥划分，$u_{ij}(\mathcal{P}) = \mathbf{1}\{i, j \text{ 同组}\}$。相关聚类可最小化加权的成对不一致损失 (Bansal et al., 2004)

$$\widehat{\mathcal{P}} = \arg\min_{\mathcal{P} \in \mathfrak{P}} R_{\widehat{p}}(\mathcal{P}), \qquad R_p(\mathcal{P}) = \sum_{(i,j) \in E} a_{ij}\{p_{ij}(1 - u_{ij}) + (1 - p_{ij})u_{ij}\}. \tag{9}$$

其中 $\mathfrak{P}$ 为预先规定的划分空间，$a_{ij} \geq 0$ 且 $\sum_E a_{ij} = 1$。各项为边际概率下的期望错误，可直接加总，允许记录对之间存在相关性。所有同组指标来自同一划分，因而满足传递性。若加入几何损失或簇数惩罚，应在开发材料上确定权重。

以 $h_{ij} = \mathbf{1}\{p_{ij} > 1/2\}$ 替代 p_{ij}，目标即为最小化二元判断与划分之间的加权不一致数。严格硬约束另要求所有 $u_{ij} = h_{ij}$，有冲突时可能无可行解。表5取 $p_{AB} = 0.9$、$p_{BC} = 0.6$、$p_{AC} = 0.2$，按等权报告损失总量。二元方案有三个并列最优解，概率方案选出 $\{A, B\} \mid \{C\}$。

表 5: 三条记录的关系冲突与整体划分：构造计算

划分	概率不一致损失	二元不一致数
$\{A, B, C\}$	1.3	1
$\{A, B\} \mid \{C\}$	0.9	1
$\{A, C\} \mid \{B\}$	2.3	3
$\{B, C\} \mid \{A\}$	1.5	1
$\{A\} \mid \{B\} \mid \{C\}$	1.7	2

5.4 概率误差与查询覆盖

以下误差界利用式(9)的线性形式，证明见附录A。

命题 1. *固定查询集合 E、权重和划分空间。令 r_{ij} 为目标关系的真实边际概率，$\mathcal{P}^*$ 为 R_r 的最小化解。若计算所得 $\widehat{\mathcal{P}}$ 满足 $R_{\widehat{p}}(\widehat{\mathcal{P}}) \leq \inf_{\mathcal{P} \in \mathfrak{P}} R_{\widehat{p}}(\mathcal{P}) + \varepsilon$，则*

$$R_r(\widehat{\mathcal{P}}) - R_r(\mathcal{P}^*) \leq 2 \sum_{(i,j) \in E} a_{ij} |\widehat{p}_{ij} - r_{ij}| + \varepsilon. \tag{10}$$

式(10)约束的是查询集合 E 上的成对风险。图外关系仍可能有多种与已查询结果相容的分组，应分别报告查询损失和完整划分的一致性。近邻对有助于细分相似记录，跨组查询可检验桥接，随机抽查可发现候选图之外的同组关系。自适应查询应保存选择路径，比较来源时采用共同的查询集合。

5.5 聚类评价

参考划分应与关系标准一致。调整兰德指数（ARI）评价两个划分的一致性，成对错误评价同组关系的恢复 (Hubert and Arabie, 1985)。比较还可报告概率评分、冲突、簇数和运行间变化。几何指标描述表示空间中的紧密程度，机制划分则用按机制标定的参考材料评价。

同组关系可直接进入划分损失，也可辅助选择聚类粒度。三元组判断给出相对接近程度，可用于训练表示。固定下游算法和查询集合可比较判断来源，固定来源可比较二元和概率读取。第7.1节实施后一种比较。

6 序数测量与记录链接

6.1 等级分布与测量变量

序数测量依据有序规程记录程度。模型可按等级说明提供分布 $\widehat{p}_{ik}$，Jev 的 Score 按等级索引汇总得分 (TypeSafe AI, 2026d)。设研究者采用编码 $g(k)$，可计算

$$\widehat{s}_i(g) = \sum_{k=0}^{K-1} g(k)\widehat{p}_{ik}, \qquad \widehat{t}_i(c) = \sum_{k \geq c} \widehat{p}_{ik}. \tag{11}$$

$\widehat{s}_i(g)$ 依赖编码间距，$\widehat{t}_i(c)$ 是达到给定等级阈值的赋值概率。序数回归可利用等级次序 (McCullagh, 1980)。若报告数值均值，需说明所用间距的实质含义。

以 $A = (0.6, 0, 0.4)$ 和 $B = (0, 1, 0)$ 为例，编码 $(0, 1, 2)$ 得到 0.8 和 1，编码 $(0, 1, 5)$ 得到 2 和 1。得分排序随编码反转，达到最高等级的概率始终为 0.4 和 0。应根据研究目标选择阈值比例、等级分布或有间距依据的数值汇总。

Gao et al. (2026) 发现所研究决策模型的等级选择较参考标签更集中。评分评价应检查极端等级的识别、评分一致性和等级使用。跨组比较时，各组规程应表达相同程度，参考样本应覆盖各等级。多维构念可分项评分，再按理论关系纳入分析。

6.2 实体关系与链接后的统计单位

记录链接识别不同记录是否来自同一实体。概率链接依据字段比较证据评价匹配 (Fellegi and Sunter, 1969)，语义判断可辅助比较别名、简称及描述。候选生成界定待判断记录对，整体匹配规则决定最终实体关系。

设 $\widehat{p}_{ij}$ 为候选对的匹配概率，C_{FP} 和 C_{FN} 分别为误链接和漏链接成本。若概率与匹配目标一致，按这两项成本链接记录对的条件为

$$\widehat{p}_{ij} > \frac{C_{\mathrm{FP}}}{C_{\mathrm{FP}} + C_{\mathrm{FN}}}. \tag{12}$$

两表一对一链接还须满足唯一匹配，实体去重则要求同一实体关系具有传递性。除候选覆盖、误链接和漏链接外，评价应报告实体计数、事件计数或回归结果的变化。错误合并可能减少实体数并混合属性，漏合并可能增加重复计数。

7 比较评价与研究议程

7.1 构造聚类研究的设计

构造实验将三种产品与三种主要故障机制交叉，得到九条投诉记录（表6），参考划分按机制分为三组。各次实验固定记录、参考关系和表示，仅改变查询集合及模拟判断。关系分数均按预设条件生成，研究未调用语言模型或 Jev。

表示基线取 $z_i = (2e_{\mathrm{product}(i)}, e_{\mathrm{mechanism}(i)})$，$e$ 为对应维度的单位向量。该表示赋予产品维度更大权重。固定 $K = 3$，枚举相应划分，最小平方误差为 6，所得产品划分与机制划分的 ARI 为 $-1/3$。

表 6: 九条投诉原型：构造记录及预设主要机制

主要机制	智能门锁	烟雾报警器	室内温控器
供电模块失效	更换合格电池后仍无法通电，供电模块无输出	更换合格电池后仍无法通电，供电模块无输出	更换合格电池后仍无法通电，供电模块无输出
断电后配置丢失	断电后已保存的密码丢失，需重新配置	断电后已保存的报警阈值丢失，需重新配置	断电后已保存的时段设置丢失，需重新配置
传感测量失真	无人触碰时持续报告开门	室内无烟时持续报告烟雾	温度恒定时持续报告升温

每次随机排列全部 36 个记录对，分别取前 12、24 和 36 对作为嵌套查询集合。每种条件重复 1,000 次，随机种子为 20261005。关系方法在全部 21,147 个划分上精确最小化式(9)，簇数由划分决定。主规则依次优先选择与产品关系不一致最少、簇数最少及枚举靠前的最优解。

记 $r_{ij} = \mathbf{1}\{\mathrm{mechanism}(i) = \mathrm{mechanism}(j)\}$，均匀抽取记录对时同组先验为 $\pi = 9/36 = 0.25$。关系判断采用四种条件。

1. **判断全部正确**。返回 $p_{ij} = r_{ij}$，用于考察有限覆盖。
2. **异质可靠度**。各记录对以相同概率取 $h_{ij} = 0.95$ 或 0.80，模拟二元信号 S_{ij} 以概率 h_{ij} 等于 r_{ij}，再按式(13)计算概率。
3. **过度集中**。沿用异质条件的信号和查询集合，计算概率时统一使用 $h = 0.99$。
4. **标准偏移**。沿用可靠度生成机制，改按“产品相同”产生信号，以机制关系评价。

异质可靠度条件按给定先验和可靠度计算边际概率

$$p(S,h) = \begin{cases} \dfrac{h\pi}{h\pi + (1-h)(1-\pi)}, & S = 1, \\ \dfrac{(1-h)\pi}{(1-h)\pi + h(1-\pi)}, & S = 0. \end{cases} \tag{13}$$

异质条件的概率以机制同组关系为目标，标准偏移条件则以产品同组关系为目标。两种读取方式共用查询图、划分空间及并列解选择规则。另行计算成对判断误差、Brier 分数及严格约束可行比例。蒙特卡洛标准误由各次实验的指标计算，配对差异的标准误依据同次实验的指标差计算。

7.2 数值结果及其解释

表 7: 查询预算、判断质量与划分结果：每个条件重复 1,000 次

判断条件	B	判断错误率	Brier	二元 ARI	概率 ARI	严格可行（%）
判断正确	12	0.0000	0.0000	0.3568	0.3568	100.0
	24	0.0000	0.0000	0.8646	0.8646	100.0
	36	0.0000	0.0000	1.0000	1.0000	100.0
异质可靠度	12	0.1297	0.0913	0.1711	0.1921	62.1
	24	0.1266	0.0891	0.5067	0.5733	9.0
	36	0.1265	0.0897	0.7336	0.7717	1.3
过度集中	12	0.1297	0.1241	0.1711	0.1719	62.1
	24	0.1266	0.1211	0.5067	0.5172	9.0
	36	0.1265	0.1210	0.7336	0.7495	1.3
标准偏移	12	0.4970	0.3503	-0.2332	-0.2308	62.6
	24	0.5005	0.3519	-0.2601	-0.2481	7.9
	36	0.4985	0.3515	-0.2947	-0.2620	1.3

所有指标以机制关系或机制划分为参考。ARI 为重复实验的平均调整兰德指数。二元 ARI 使用允许违反判断的最小不一致解。严格可行比例单独记录全部二元约束具有共同划分的次数。异质可靠度与过度集中条件共享二元信号，因此判断错误率、二元解及严格可行比例相同。全部未舍入指标和蒙特卡洛标准误随稿提供。

判断全部正确时，查询 12 和 24 对的平均 ARI 分别为 0.3568 和 0.8646，完整恢复参考划分的比例分别为 0.6% 和 39.4%。检查主结果后，以最少簇数优先、枚举顺序次之的规则补做敏感性分析。两种预算的平均 ARI 分别为 0.4905 和 0.9896，出现并列最优的比例分别为 99.5% 和 60.6%。完整查询图在两种规则下均唯一恢复参考划分。

异质可靠度条件下，主规则所得概率 ARI 在三个预算下均高于二元 ARI。查询 24 和 36 对时，平均差异分别为 0.0666 和 0.0381，配对蒙特卡洛标准误分别为 0.0058 和 0.0051。统一按 $h = 0.99$ 读取相同信号后，36 次查询的 Brier 分数由 0.0897 升至 0.1210，概率 ARI 降至 0.7495。

异质条件的完整图上，二元与概率损失分别在 54.4% 和 31.2% 的重复中出现并列最优。最少簇数优先时，两者 ARI 分别为 0.8469 和 0.7771，排序与主规则相反。式(10)约束的是成对损失，比较划分恢复时还应报告并列解的选择规则。

异质条件下，查询由 12 对增至 36 对时，严格约束可行比例由 62.1% 降至 1.3%。完整图上，约 14.7% 的三元组出现两条正边和一条负边。标准偏移条件的概率 ARI 在三个预算下均为负，更多查询强化了按产品分组的结构。这些结果对应九条固定原型、均匀查询、指定噪声和精确求解。

判断质量还可按下游分析目标评价。附录B中的 SMS 辅助分数均值接近归档标签比例，但逐条分数与标签的相关性较弱。在所比较的核验方案中，简单随机抽样的标签均值具有最低均方误差（MSE）。辅助分数能否提高估计效率取决于其与分析变量的关系及核验设计。

7.3 判断来源、读取方式与总成本

分类研究可在相同目标任务标签预算下比较通用模型、专门决策模型与传统监督方案。用标签预算曲线评价少标签效率，以相同基础模型考察适配作用。两个零样本部署同时变更多项配置，若要估计各项配置的作用，可逐项改变模板、量化或概率读取程序。费用包括模型调用、参数选择、训练与人工核验。

真实语料的聚类比较宜统一关系标准与独立参考划分，并固定候选图和查询集合。常规表示聚类作为基线，通用语言模型与专门模型在相同划分算法下比较二元判断。对可读出概率的系统，再比较二元损失和概率损失（表8）。

表 8: 语义标准指导的聚类：真实语料比较设计

待评价因素	固定条件	比较内容与指标
额外关系信息	语料、目标标准、参考材料	常规表示聚类与关系辅助方案（ARI、成对误差及费用）
关系判断来源	输入记录对、标准、查询图、划分算法	通用语言模型与决策模型（关系误差、划分质量及总投入）
概率读取方式	同一来源、同一输出、同一划分空间	二元损失与概率损失（Brier 分数、配对 ARI 差异及冲突）
查询选择	同一来源、标准、预算和统计方法	随机、近邻及跨组查询（完整关系恢复及图外漏检）
标准稳定性	同一语料和模型版本	等义改写、输入顺序与重复运行（判断及划分变化）

由领域人员按同一规程形成参考划分，记录分歧及裁决。用开发材料选择标准、校准方法和算法参数，用独立材料评价。成对判断共享记录时，以记录或语料为重抽样单位以保留相关结构，并在候选图内外核验关系。评价应同时报告划分质量、查询费用、标准制定和人工核验投入。

8 结论

语义决策模型允许研究者按自然语言标准获取类别、关系与等级。所得信息可用于分类监督、聚类约束和序数测量，也可通过实体链接界定统计单位。零样本分类、弱监督和约束聚类为这些用途提供了方法基础。

在标题案例中，任务微调减少了漏检，同时增加了误报，应用收益取决于错误代价及标签投入。构造聚类实验显示，划分恢复受查询覆盖影响，概率加权的表现还随判断质量和并列解选择规则变化。真实语料研究可在同一标准和预算下比较判断来源，并以独立核验材料检验局部误差、划分质量及下游统计结果。

A 成对风险误差界的证明

对任意划分 $\mathcal{P}$，$u_{ij} \in \{0,1\}$，因而

$$|R_{\widehat{p}}(\mathcal{P}) - R_r(\mathcal{P})| = \left| \sum_E a_{ij}(\widehat{p}_{ij} - r_{ij})(1 - 2u_{ij}) \right| \tag{14}$$

$$\leq \sum_E a_{ij}|\widehat{p}_{ij} - r_{ij}| =: \delta. \tag{15}$$

由 $\widehat{\mathcal{P}}$ 的近似最优性可得

$$R_r(\widehat{\mathcal{P}}) \leq R_{\widehat{p}}(\widehat{\mathcal{P}}) + \delta \tag{16}$$

$$\leq R_{\widehat{p}}(\mathcal{P}^*) + \varepsilon + \delta \tag{17}$$

$$\leq R_r(\mathcal{P}^*) + \varepsilon + 2\delta. \tag{18}$$

B 下游补充案例：SMS 分数与总体比例

本附录复用 SMS Spam Collection 的抽样设计结果 (Almeida and Hidalgo, 2011)。下载档案含 5,574 行记录和 747 个垃圾短信标签，403 次重复文本出现各保留为一个记录行，目标为归档标签的固定总体比例 0.1340。固定版本的自然语言推断模型 cross-encoder/nli-MiniLM2-L6-H768 对正常通信和未经请求的推广或欺诈性短信两项描述给出蕴含 logit，softmax 后所得垃圾短信分数 f_i 用作辅助变量 (Sentence Transformers, n.d.)。

若全体分数已知，按简单随机抽样（SRS）从固定语料总体 U 中不放回核验 n 行，固定系数差值估计为

$$\widehat{\mu}_\lambda = \lambda \bar{f}_U + \frac{1}{n}\sum_{i \in V}(Y_i^{\mathrm{ref}} - \lambda f_i), \qquad \mathrm{Var}_V(\widehat{\mu}_\lambda) = \left(1 - \frac{n}{N}\right)\frac{S^2_{Y-\lambda f}}{n}. \tag{19}$$

其中 N 为总体行数，S^2 为分母 $N-1$ 的有限总体方差。辅助变量通过残差方差影响效率，这一原理与模型辅助估计及预测辅助推断衔接 (Särndal et al., 1992; Angelopoulos et al., 2023)。

两个核验预算各重复 10,000 次，结果摘要见表9。分数与标签的相关系数为 -0.0545。根据全体标签计算，SRS 最优固定系数为 -0.1463，理论方差降幅约 0.30%。这组分数通过固定系数提高抽样效率的空间较小。

在所比较的方案中，SRS 标签均值的 MSE 最低。先导调权较单位权重先导方案的 MSE 低，结果受弱关联、系数估计变异和先导投入影响。预测均值为 0.13818，接近标签比例，记录层面的相关性较弱。总体汇总误差和辅助变量的抽样效率应分别评价。

表 9: 复用 SMS 抽样设计结果：MSE 乘以 10^4

估计方案	核验预算 200	核验预算 400
SRS 标签均值	5.568	2.637
SRS 差值估计，$\lambda = 1$	6.604	3.113
先导分层校正，$\lambda = 1$	10.117	3.603
先导调权差值估计	9.642	3.413

两个先导方案均使用 80 个预算内先导标签，并沿用同一分层、分配和主阶段样本。调权系数由先导标签估计，在主阶段固定。完整设计、偏差、区间覆盖率和复现记录见既有 SMS 材料。表中目标均为归档标签的固定总体比例。

C 复现条件与材料

分析脚本、逐条预测、来源校验值与未舍入结果见GitHub 公开复现材料。

分类材料取自课程项目 (LeoAndJellyfish, 2026)。固定提交号为 1b0ce28d265454680b5b383bbb7ff0929dca688b。原训练文本 236,158 行，依次清理空行、类内重复、测试标题重叠及训练标签冲突后，训练池有 212,385 条记录。标题身份由 Unicode NFKC、大小写折叠、空白合并及首尾清理定义，训练与验证按类别分层，种子为 42。运行 scripts/title_case_analysis.py 可用 research/title_case/ 中的六项对齐预测复算指标。配对自助重抽样以 568 个正确和 395 个错误的非空标题组为单位，保持组内记录权重，固定加入 24 条空标题。重复次数 10,000，种子为 20261006，结果以一次训练得到的预测为条件。

Tev1 基础权重版本为 0b7becf017daa0e5eb222f8ce7483c8c8259c52f。微调固定 NF4 四位主干、双重量化和 BF16 计算，LoRA 秩 8、缩放系数 16、dropout 0，学习率 5×10^{-5}，有效批量 16，训练一轮，最长 512 词元。训练损失覆盖答案字母及结束标记，训练和验证提示均无截断。第 5,310 及 10,620 步的验证宏平均 F1 分别为 85.45% 和 85.91%，后者在测试前入选。未微调对照在同一模型实例中关闭适配器，两者均逐条推理。Ollama 0.35.0 使用 Q4_K_M GGUF，权重摘要随材料保存，上游 HF 版本未标明。原实验使用 Python 3.12.11，NF4 依赖 PyTorch 2.11.0、Transformers 5.14.1、PEFT 0.21.2 和 bitsandbytes 0.50.2。重分析以 Python 和 NumPy 读取保存的预测。

聚类程序 scripts/semantic_clustering_study.py 使用 Python 与 NumPy。程序通过受限增长串枚举全部划分，保存每次 ARI、严格约束可行性、汇总指标及蒙特卡洛标准误。保存目录为 research/semantic_clustering/。本文报告的重复实验固定九条原型，随机变化仅来自记录对选择和判断噪声。

SMS 部分复用 research/real_data/results.json 与 summary.csv。其模型版本固定为 b95119ce93d3e065de6214e38cd4a97b0f2f2c6d，预测文件校验值及读取描述见该目录的 provenance.json。已有复现程序为 scripts/sms_design_evaluation.py。语料总体行数依据原始下载档案解析结果报告。

参考文献

Almeida, T. and Hidalgo, J. (2011). SMS Spam Collection. UCI Machine Learning Repository. Dataset, accessed 5 October 2026.

Angelopoulos, A. N., Bates, S., Fannjiang, C., Jordan, M. I., and Zrnic, T. (2023). Prediction-powered inference. *Science*, 382(6671), 669–674.

Bansal, N., Blum, A., and Chawla, S. (2004). Correlation clustering. *Machine Learning*, 56, 89–113.

Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. *Advances in Neural Information Processing Systems*, 36.

Fellegi, I. P. and Sunter, A. B. (1969). A theory for record linkage. *Journal of the American Statistical Association*, 64(328), 1183–1210.

Gao, T., Li, J., Li, Z., Chang, Y., and Wu, Y. (2026). More choices, fewer decisions: Ordinal-scale bias in JEV-like direct-decision models. arXiv:2609.38827v1. Preprint.

Grimmer, J. and Stewart, B. M. (2013). Text as data: The promise and pitfalls of automatic content analysis methods for political texts. *Political Analysis*, 21(3), 267–297.

Guo, C., Pleiss, G., Sun, Y., and Weinberger, K. Q. (2017). On calibration of modern neural networks. *Proceedings of Machine Learning Research*, 70, 1321–1330.

Hubert, L. and Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2, 193–218.

Ibrahim, H. and Zaki, Y. (2026). Evaluating decision models for text annotation in computational social science. arXiv:2609.24574v2. Preprint, revised 23 September 2026.

Jia, C., Wu, W., Guo, L., Lu, Z., Chen, C., and Ong, K.-L. (2026). Optimized algorithms for text clustering with LLM-generated constraints. arXiv:2601.11118v1. AAAI-26 paper version.

Joy, S. S. (2026). Do System One decisions add up? A study of probabilistic coherence. arXiv:2609.33971v1. Preprint.

LeoAndJellyfish (2026). 论文标题提取错误识别：课程实验与复现材料. GitHub repository, fixed commit specified in Appendix C, accessed 6 October 2026.

McCullagh, P. (1980). Regression models for ordinal data. *Journal of the Royal Statistical Society, Series B*, 42(2), 109–127.

Ratner, A., Bach, S. H., Ehrenberg, H., Fries, J., Wu, S., and Ré, C. (2017). Snorkel: Rapid training data creation with weak supervision. *Proceedings of the VLDB Endowment*, 11(3), 269–282.

Särndal, C.-E., Swensson, B., and Wretman, J. (1992). *Model Assisted Survey Sampling*. Springer, New York.

Sentence Transformers (n.d.). Cross-encoder for natural language inference: nli-MiniLM2-L6-H768. Model card and fixed model files; revision specified in Appendix C, accessed 5 October 2026.

Tan, Z., Li, D., Wang, S., Beigi, A., Jiang, B., Bhattacharjee, A., Karami, M., Li, J., Cheng, L., and Liu, H. (2024). Large language models for data annotation and synthesis: A survey. In *Proceedings of EMNLP*, pp. 930–957.

Together AI (2026). Tev1-4B-experimental. Model card, fixed revision specified in Appendix C, accessed 6 October 2026.

TypeSafe AI (2026a). Choice. Technical documentation, accessed 5 October 2026.

TypeSafe AI (2026b). Introduction. Technical documentation, accessed 5 October 2026.

TypeSafe AI (2026c). Noul. Technical documentation, accessed 5 October 2026; response definition rechecked 5 October 2026.

TypeSafe AI (2026d). Score. Technical documentation, accessed 5 October 2026.

Viswanathan, V., Gashteovski, K., Lawrence, C., Wu, T., and Neubig, G. (2024). Large language models enable few-shot clustering. *Transactions of the Association for Computational Linguistics*, 12, 321–333.

Wagstaff, K., Cardie, C., Rogers, S., and Schroedl, S. (2001). Constrained k-means clustering with background knowledge. In *Proceedings of ICML*, pp. 577–584.

Wang, H., Zhang, T., Yang, R., and Xu, J. (2025). Cequel: Cost-effective querying of large language models for text clustering. arXiv:2504.15640v2. Preprint, revised 21 August 2025.

Yin, W., Hay, J., and Roth, D. (2019). Benchmarking zero-shot text classification: Datasets, evaluation and entailment approach. In *Proceedings of EMNLP-IJCNLP*, pp. 3914–3923.

Zhang, Y., Wang, Z., and Shang, J. (2023). ClusterLLM: Large language models as a guide for text clustering. In *Proceedings of EMNLP*, pp. 13903–13920.